IMPLEMENTACIÓN DE UN PIPELINE BATCH SERVERLESS EN AWS PARA EL ANÁLISIS DE CHURN DE CLIENTES EN UNA EMPRESA DE TELECOMUNICACIONES

Cesar Augusto Amortegui Hernández

Trabajo de grado presentado como requisito para optar al título de:
Especialista en Ingeniería de datos e IA con AWS

Instructor:
José Zamalloa

Smart Data
Bogotá, Colombia
17/Abr/2026

Tabla de Contenido

1. Descripción del Escenario 5

2. Arquitectura de la Solución 6

3. Implementación del Pipeline 7

3.1 Ingesta de datos 8

3.2 Catalogación de datos (Raw Layer) 8

3.3 Exploración y perfilamiento de datos 9

3.4 Transformación de datos (ETL) 9

3.5 Almacenamiento de datos procesados 10

3.6 Catalogación de datos procesados 10

3.7 Análisis de datos con Athena 11

3.8 Integración con Machine Learning 11

3.9 Validación y evidencias 13

4. Resultados y análisis 14

4.1 Validación del pipeline 14

4.2 Análisis de churn por tipo de contrato 14

4.3 Análisis de churn por antigüedad del cliente 15

4.4 Relación entre cargos y churn 15

4.5 Aporte del modelo de machine learning 16

4.5.1. Evaluación del modelo de machine learning 16

4.5.1.1 Curva ROC y AUC 16

4.5.1.2 Matriz de confusión 17

4.6 Valor de negocio 18

5. Conclusiones 20

6. Bibliografía 22

Tabla de Ilustraciones

Ilustración 1. Arquitectura AWS. 6

Ilustración 2. S3 Raw 8

Ilustración 3. Crawlers 8

Ilustración 4. Glue Job 10

Ilustración 5. Archivo tipo parquet processed 10

Ilustración 6. Consulta Athena 11

Ilustración 7. Amazon SageMaker 12

Ilustración 8. Amazon SageMaker Entrenamiento 12

Ilustración 9. VPC Amazon SageMaker 13

Ilustración 10. Resultados Curva Roc 17

Ilustración 11. Matriz de Confusion. 18

1. Descripción del Escenario

En el sector de telecomunicaciones, la retención de clientes es un factor crítico debido al impacto directo que tiene la cancelación del servicio (*churn*) sobre los ingresos y los costos asociados a la adquisición de nuevos clientes. La pérdida de clientes no solo implica una disminución en los ingresos futuros, sino que obliga a las organizaciones a invertir en estrategias de captación para reemplazarlos, lo cual generalmente representa un costo significativamente mayor que la retención de clientes existentes.

En este contexto, las organizaciones requieren capacidades analíticas que permitan comprender el comportamiento de los clientes y anticipar su posible abandono. Por esta razón, resulta necesario contar con una arquitectura de datos que permita integrar, transformar y analizar información de clientes, facilitando la identificación de patrones asociados a su comportamiento.

El churn es un indicador clave en industrias basadas en suscripción, como telecomunicaciones, ya que representa el porcentaje de clientes que cancelan un servicio en un periodo determinado. Su análisis permite evaluar la fidelización del cliente y diseñar estrategias orientadas a la retención.

El presente proyecto desarrolla una solución orientada al análisis de churn a partir de un dataset estructurado que contiene variables demográficas, servicios contratados, permanencia, método de pago, cargos mensuales y cargos totales, además de la variable objetivo de cancelación. El dataset utilizado corresponde a un conjunto de datos de churn de clientes del sector telecomunicaciones, ampliamente utilizado en ejercicios de analítica y machine learning.

Para dar respuesta a esta necesidad, se realizó el diseño e implementación de un pipeline batch serverless en AWS que cubre las etapas de ingesta, catalogación, transformación, almacenamiento y análisis. Como extensión opcional, se incorpora una fase de machine learning para predecir churn a partir de los datos transformados.

2. Arquitectura de la Solución

La arquitectura implementada corresponde a un pipeline de ingeniería de datos basado en servicios administrados de AWS, diseñado bajo un enfoque serverless y orientado a un modelo de data lake. Esta arquitectura permite procesar datos de manera escalable, eficiente y con baja complejidad operativa, alineándose con las buenas prácticas del Amazon Web Services Well-Architected Framework.

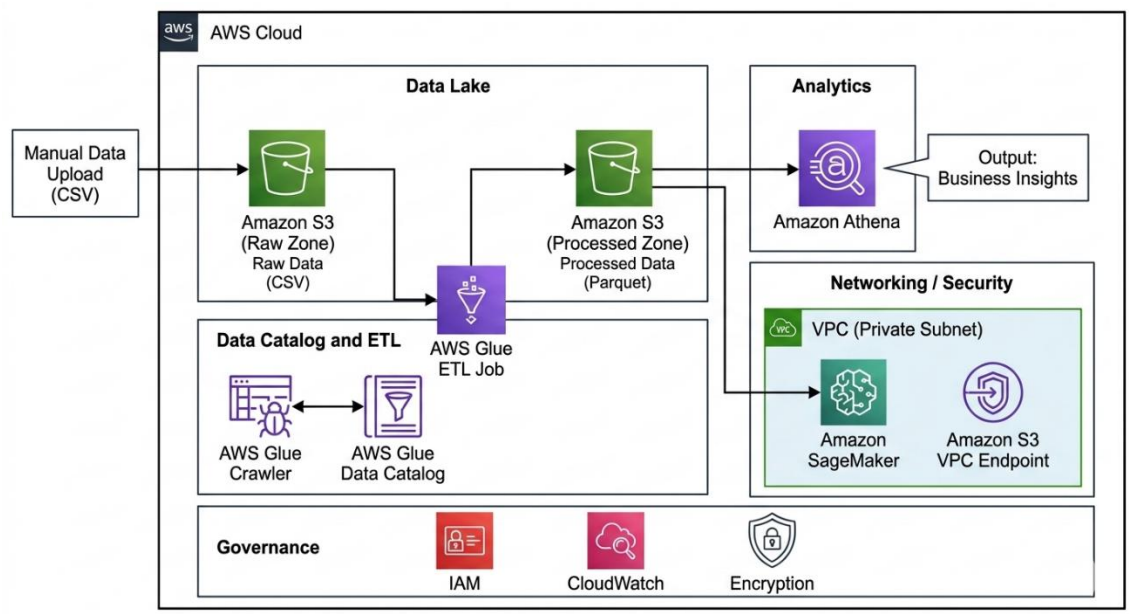

Ilustración 1. Arquitectura AWS.

En la ilustración 1, podemos el flujo de datos que inicia con la carga manual del dataset en formato CSV en Amazon S3, dentro de una zona denominada *raw*, la cual conserva los datos en su estado original para garantizar trazabilidad. A partir de esta capa, se implementa un proceso de catalogación mediante AWS Glue Crawler, que permite identificar automáticamente la estructura del dataset y registrar sus metadatos en el AWS Glue Data Catalog.

Posteriormente, se ejecuta un proceso de transformación utilizando AWS Glue ETL Job, el cual aplica técnicas de limpieza, normalización y enriquecimiento de datos. Entre las principales transformaciones se incluyen la eliminación de espacios en blanco, la conversión de tipos de datos y la generación de variables derivadas, como la segmentación de clientes según su antigüedad (*tenure_group*). El resultado de este proceso es almacenado en Amazon S3 en

formato Parquet dentro de la zona *processed*, optimizando el rendimiento de las consultas analíticas.

Para la capa de análisis, se utiliza Amazon Athena, que permite ejecutar consultas SQL directamente sobre los datos almacenados en S3 sin necesidad de infraestructura adicional. Esto facilita la exploración de datos y la generación de insights relacionados con el comportamiento de churn.

Como extensión de la arquitectura, se incorpora un componente de machine learning mediante Amazon SageMaker, el cual permite entrenar modelos de clasificación binaria sobre los datos procesados. Este componente se implementó dentro de una Virtual Private Cloud (VPC) con subredes privadas y acceso a S3 mediante VPC Endpoints, mejorando el aislamiento y la seguridad de los datos.

Adicionalmente, la arquitectura incluye una capa transversal de gobernanza y seguridad, donde se implementan controles mediante AWS Identity and Access Management (IAM), monitoreo con Amazon CloudWatch y mecanismos de cifrado en S3. Estos elementos permiten garantizar la protección de los datos y el control de acceso a los recursos del pipeline.

En conjunto, la arquitectura propuesta integra componentes de almacenamiento, procesamiento, análisis y machine learning en un flujo cohesivo, permitiendo transformar datos crudos en información valiosa y capacidades predictivas para la toma de decisiones.

3. Implementación del Pipeline

La implementación del pipeline se desarrolló siguiendo un enfoque estructurado que cubre las etapas de ingesta, catalogación, transformación, almacenamiento y análisis de datos, utilizando servicios administrados de Amazon Web Services.

3.1 Ingesta de datos

El proceso inicia con la carga manual del dataset en formato CSV en Amazon S3, dentro de la carpeta *raw,* ver abajo ilustración 2. Esta capa conserva los datos en su estado original, permitiendo mantener trazabilidad y facilitar procesos de auditoría o reprocesamiento.

Desde una perspectiva técnica, el almacenamiento en S3 permite desacoplar la ingesta del procesamiento, habilitando una arquitectura escalable y resiliente.

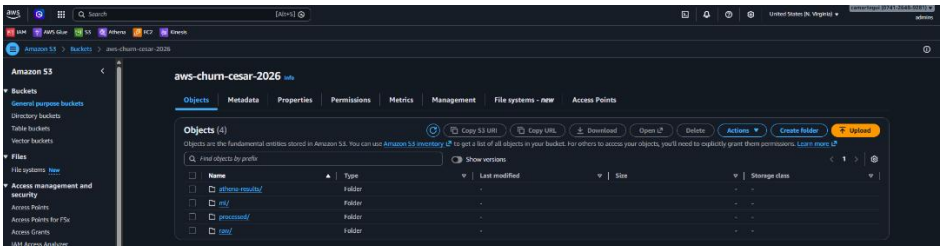

Ilustración 2. S3 Raw

3.2 Catalogación de datos (Raw Layer)

Para habilitar el descubrimiento de datos, como se ve en la ilustración 3, se configuró un AWS Glue Crawler sobre la carpeta *raw*, el cual permitió identificar automáticamente el esquema del dataset y registrar la información en el Glue Data Catalog.

El crawler generó una tabla inicial que fue posteriormente ajustada en su nomenclatura para mejorar la claridad semántica, siguiendo buenas prácticas de catalogación de datos.

Este proceso permitió abstraer el acceso a los datos y facilitar su uso en herramientas analíticas como Athena.

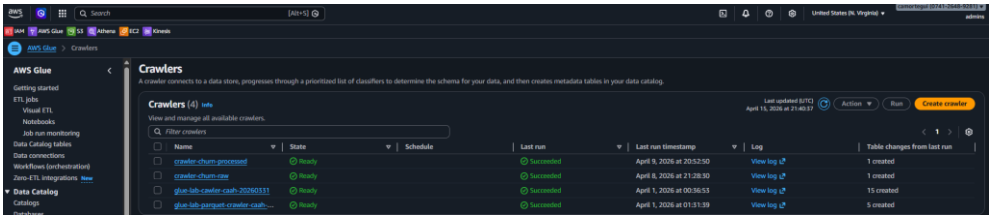

Ilustración 3. Crawlers

3.3 Exploración y perfilamiento de datos

Previo a la transformación, se realizó un análisis exploratorio del dataset mediante notebooks en PySpark, con el objetivo de identificar problemas de calidad de datos y definir las transformaciones necesarias.

Durante esta fase se identificaron aspectos como:

- presencia de espacios en blanco en variables categóricas
- valores vacíos en la columna *TotalCharges*
- inconsistencias en tipos de datos
- distribución de variables clave como *tenure* y *Churn*

Este proceso permitió diseñar una estrategia de limpieza basada en evidencia, evitando transformaciones arbitrarias.

3.4 Transformación de datos (ETL)

La transformación de los datos se implementó mediante un AWS Glue ETL Job, utilizando una combinación de AWS Glue Studio (interfaz visual) y código PySpark para un mayor control sobre las transformaciones.

Entre las principales transformaciones realizadas se incluyen:

- eliminación de espacios en blanco mediante funciones de normalización
- conversión de valores vacíos a valores nulos
- transformación de la columna *TotalCharges* a tipo numérico
- estandarización de variables categóricas
- creación de la variable derivada *tenure_group*, que segmenta a los clientes según su antigüedad

Desde el punto de vista técnico, estas transformaciones se implementaron utilizando funciones de PySpark como trim(), when(), cast() y operaciones de manipulación de columnas, garantizando la consistencia del dataset.

El uso de PySpark permitió manejar eficientemente el procesamiento de datos y asegurar reproducibilidad en el pipeline.

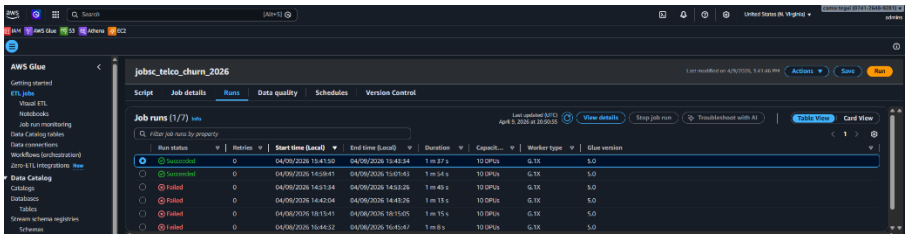

Ilustración 4. Glue Job

3.5 Almacenamiento de datos procesados

Los datos transformados fueron almacenados en Amazon S3 dentro de la carpeta *processed*, utilizando formato Parquet.

La elección de este formato responde a su eficiencia en almacenamiento y consulta, ya que permite:

- compresión de datos
- lectura columnar
- reducción del volumen de datos escaneados

Esto impacta directamente en el rendimiento y costo de consultas en Athena.

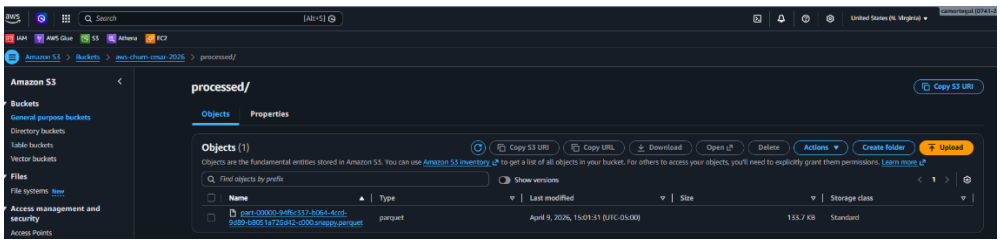

Ilustración 5. Archivo tipo parquet processed

3.6 Catalogación de datos procesados

Posteriormente, se configuró un segundo AWS Glue Crawler sobre la carpeta *processed*, con el fin de registrar la estructura final del dataset en el Glue Data Catalog.

Este paso permitió exponer los datos transformados como una tabla analítica, facilitando su consumo por herramientas de consulta.

Se validó que las transformaciones realizadas en el ETL se reflejaran correctamente en el esquema, incluyendo la presencia de la variable *tenure_group* y la correcta tipificación de las columnas.

3.7 Análisis de datos con Athena

Una vez catalogados los datos procesados, se utilizó Amazon Athena para ejecutar consultas SQL sobre el dataset.

Se realizaron consultas orientadas a identificar patrones de churn, tales como:

- tasa de cancelación por tipo de contrato
- comportamiento de churn según la antigüedad del cliente
- relación entre cargos mensuales y cancelación

El uso de Athena permitió realizar análisis sin necesidad de infraestructura adicional, aprovechando el modelo serverless de AWS.

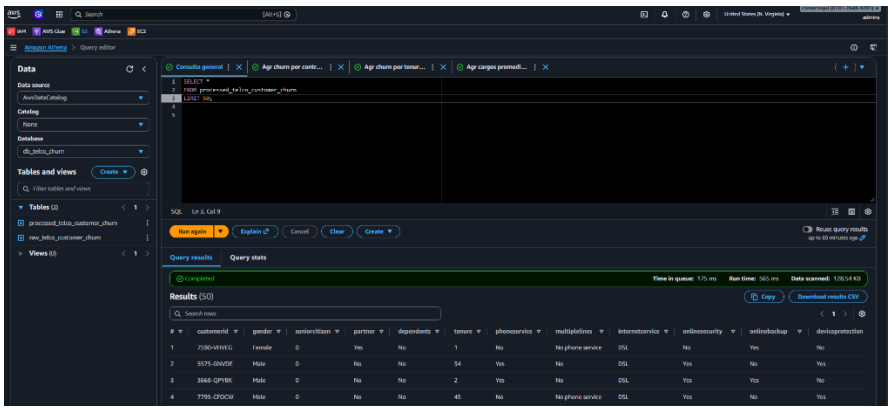

Ilustración 6. Consulta Athena

3.8 Integración con Machine Learning

Como extensión del pipeline, se integró un proceso de preparación de datos para machine learning utilizando notebooks en Amazon SageMaker.

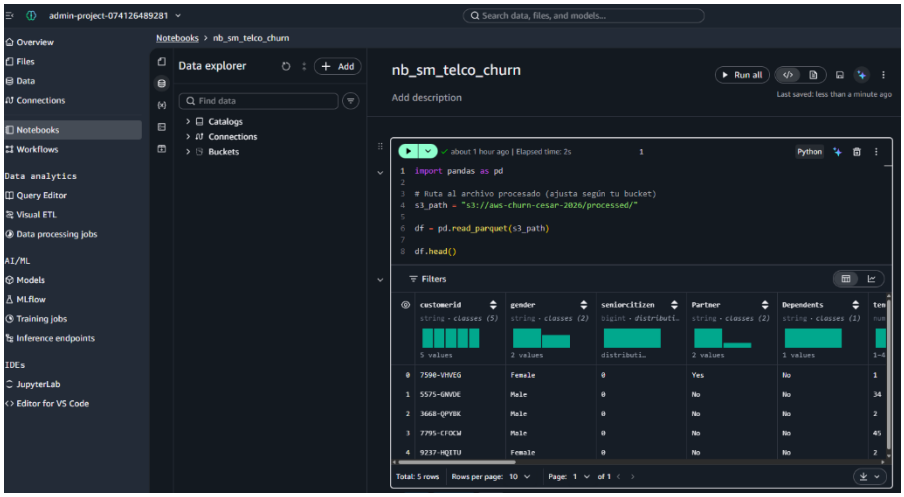

Ilustración 7. Amazon SageMaker

Durante esta fase se realizaron las siguientes actividades:

- transformación de la variable objetivo *Churn* a formato binario
- eliminación de variables no relevantes como identificadores
- codificación de variables categóricas mediante *one-hot encoding*
- división del dataset en conjuntos de entrenamiento y validación
- generación de archivos en formato compatible con SageMaker

Posteriormente, se configuró y ejecutó un proceso de entrenamiento utilizando el algoritmo XGBoost para clasificación binaria.

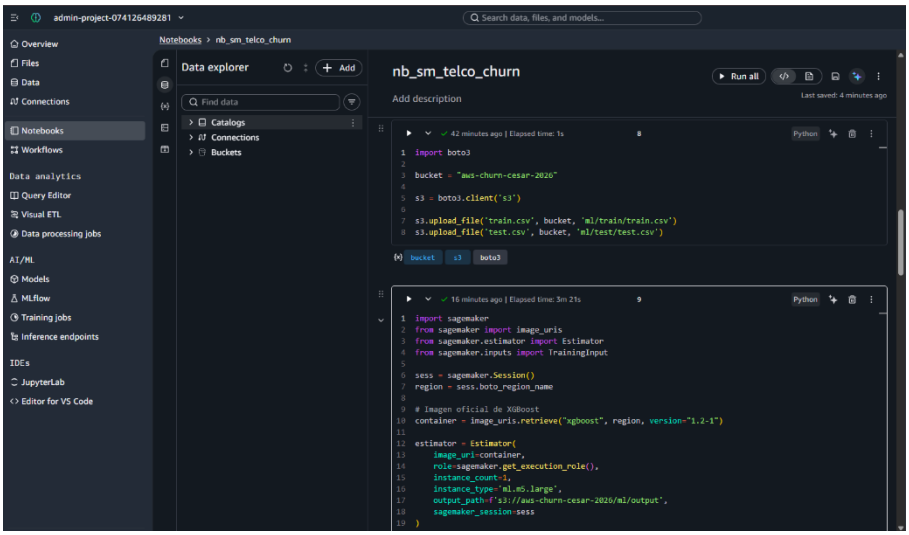

Ilustración 8. Amazon SageMaker Entrenamiento

Para fortalecer el componente de machine learning, se creó una Virtual Private Cloud (VPC) con subredes privadas y un gateway endpoint para Amazon S3. Esta configuración permitió

ejecutar el entrenamiento del modelo en SageMaker dentro de una red privada y acceder a los datos y artefactos almacenados en S3 sin necesidad de internet público. SageMaker soporta este enfoque mediante la configuración de subnets y security groups en el parámetro VpcConfig, mientras que el endpoint de S3 agrega rutas privadas desde las subredes hacia el servicio de almacenamiento.

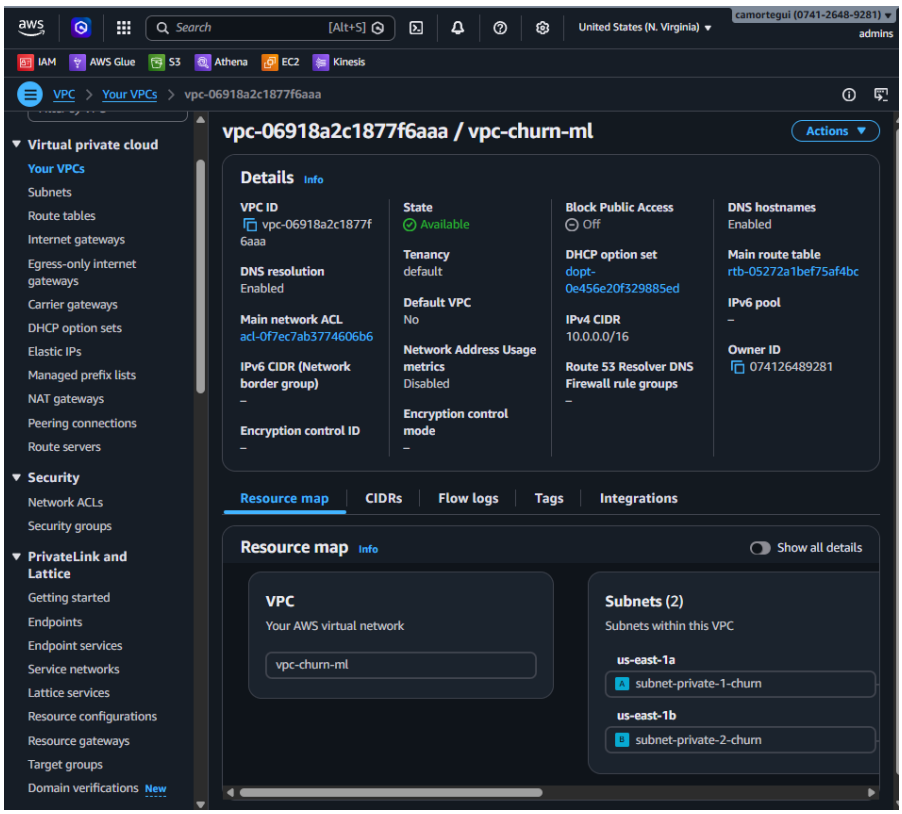

Ilustración 9. VPC Amazon SageMaker

Este componente demuestra cómo el pipeline de datos puede evolucionar hacia capacidades de analítica predictiva, integrando la ingeniería de datos con modelos de machine learning.

3.9 Validación y evidencias

Durante la implementación del pipeline se documentaron evidencias de cada etapa, incluyendo:

- almacenamiento del dataset en S3 (zona raw)
- ejecución de crawlers y tablas en Glue
- ejecución exitosa del ETL Job

- generación de archivos Parquet en la zona processed
- consultas ejecutadas en Athena
- entrenamiento del modelo en SageMaker

Estas evidencias permiten validar la correcta ejecución del pipeline y respaldar los resultados obtenidos.

4. Resultados y análisis

La implementación del pipeline permitió transformar el dataset original en una estructura analítica optimizada, habilitando la exploración y generación de insights mediante consultas SQL en Amazon Athena.

A partir de los datos procesados, se realizaron diferentes análisis orientados a identificar patrones asociados al churn de clientes, obteniendo resultados relevantes desde una perspectiva de negocio.

4.1 Validación del pipeline

Como primer resultado, se validó la correcta ejecución del pipeline mediante:

- generación de datos en formato Parquet en la zona *processed*
- correcta catalogación en AWS Glue Data Catalog
- ejecución exitosa de consultas en Athena

Esto permitió confirmar que el flujo de datos desde la ingesta hasta la capa analítica funciona de manera consistente y reproducible.

4.2 Análisis de churn por tipo de contrato

Uno de los principales hallazgos corresponde a la relación entre el tipo de contrato y la probabilidad de cancelación.

El análisis mostró que los clientes con contratos de tipo mensual (*Month-to-month*) presentan una tasa de churn significativamente mayor en comparación con aquellos que tienen contratos de largo plazo.

Desde una perspectiva de negocio, este resultado sugiere que los clientes con menor compromiso contractual son más propensos a abandonar el servicio, lo cual implica la necesidad de diseñar estrategias de retención específicas para este segmento.

4.3 Análisis de churn por antigüedad del cliente

Mediante la variable derivada *tenure_group*, se analizó el comportamiento del churn en función de la antigüedad del cliente.

Los resultados evidencian que:

- los clientes con menor antigüedad presentan una mayor probabilidad de cancelación
- a medida que aumenta la permanencia, la tasa de churn disminuye

Este patrón indica que los primeros meses del ciclo de vida del cliente son críticos para la retención, por lo que las estrategias de fidelización deben enfocarse especialmente en esta etapa.

4.4 Relación entre cargos y churn

Se analizaron los cargos mensuales y totales en relación con la cancelación del servicio.

Los resultados sugieren que:

- los clientes con cargos mensuales más altos presentan mayor propensión al churn
- el valor acumulado (*TotalCharges*) está influenciado por la antigüedad, lo que refuerza la relación entre permanencia y cancelación

Desde el punto de vista de negocio, estos hallazgos pueden ser utilizados para diseñar estrategias de precios, promociones o planes personalizados orientados a reducir la cancelación.

4.5 Aporte del modelo de machine learning

Como parte de la extensión del proyecto, se implementó un modelo de clasificación binaria utilizando Amazon SageMaker, con el objetivo de predecir la probabilidad de churn de los clientes.

Aunque el modelo desarrollado corresponde a una prueba de concepto, su implementación permitió:

- validar la viabilidad de integrar analítica predictiva en el pipeline
- transformar el análisis descriptivo en capacidades de predicción
- sentar las bases para futuros desarrollos de modelos más robustos

Este componente demuestra cómo los datos procesados pueden ser utilizados no solo para análisis retrospectivo, sino también para anticipar comportamientos futuros.

4.5.1. Evaluación del modelo de machine learning

Como parte de la extensión analítica del proyecto, se evaluó un modelo de clasificación binaria utilizando el algoritmo XGBoost, implementado en Amazon SageMaker y complementado con un modelo equivalente en el notebook para facilitar la interpretación de resultados.

La evaluación del modelo se realizó sobre un conjunto de prueba independiente, utilizando métricas estándar de clasificación.

4.5.1.1 Curva ROC y AUC

Se generó la curva ROC (*Receiver Operating Characteristic*), la cual permite analizar la capacidad del modelo para discriminar entre clientes que cancelan el servicio y aquellos que no.

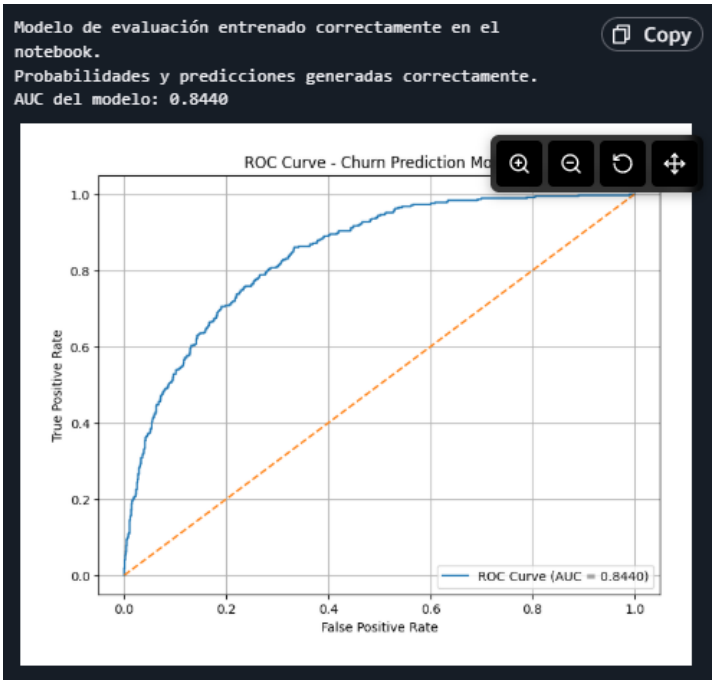

Ilustración 10. Curva ROC del modelo de churn

El modelo obtuvo un AUC de 0.8440, lo cual indica una buena capacidad de discriminación entre clientes que cancelan el servicio y aquellos que no. Este resultado sugiere que el modelo es capaz de capturar patrones relevantes en los datos y diferenciar adecuadamente entre ambas clases, siendo adecuado como prueba de concepto para un escenario de analítica predictiva. Estos resultados evidencian que el modelo no solo captura patrones relevantes en los datos, sino que puede ser utilizado como una herramienta inicial de priorización de clientes en riesgo dentro de estrategias de retención.

4.5.1.2 Matriz de confusión

La matriz de confusión permitió analizar el desempeño del modelo en términos de aciertos y errores de clasificación. Los resultados evidencian que el modelo logra identificar correctamente una proporción significativa de clientes que no presentan churn, así como una parte relevante de los clientes que sí cancelan el servicio.

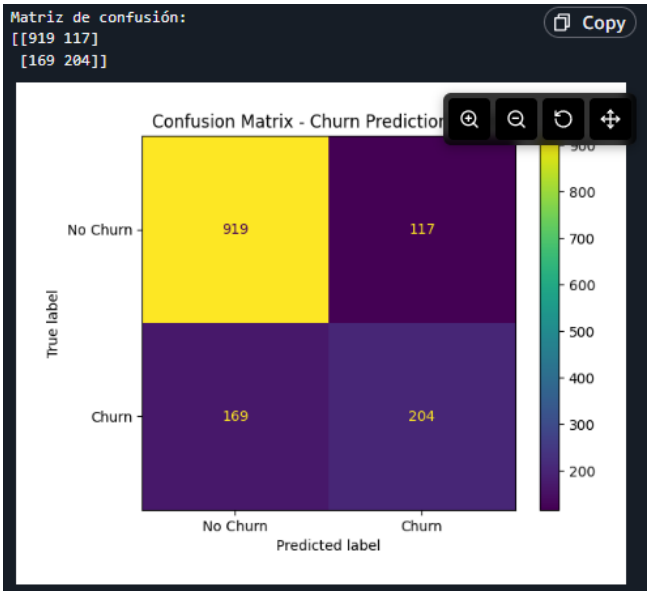

Ilustración 11. Matriz de Confusion.

Sin embargo, se observa la presencia de falsos negativos, es decir, clientes que efectivamente abandonan el servicio pero que no son identificados por el modelo. Este aspecto es particularmente importante en un contexto de negocio, ya que representa oportunidades de retención no aprovechadas.

En términos de métricas, el modelo presenta un recall aproximado del 55% para la clase de churn, lo que indica que aún existe margen de mejora en la capacidad de detección de clientes en riesgo. No obstante, el modelo demuestra ser una base sólida para una prueba de concepto, especialmente considerando su buen desempeño en términos de AUC.

Desde una perspectiva de negocio, el modelo presenta una capacidad de discriminación sólida, pero evidencia una cobertura moderada en la detección de clientes que efectivamente realizan churn, lo cual implica que identifica correctamente un grupo relevante de clientes en riesgo, pero no captura la totalidad de los casos de churn. Esto sugiere que, en un entorno real, sería necesario ajustar el umbral de decisión o aplicar técnicas de optimización orientadas a maximizar el recall.

4.6 Valor de negocio

Los resultados obtenidos permiten generar valor desde diferentes perspectivas:

- segmentación de clientes según riesgo de churn
- identificación de clientes de alto riesgo en etapas tempranas
- diseño de estrategias de retención enfocadas en contratos flexibles
- optimización de ofertas y modelos de pricing

En conjunto, estos insights contribuyen a mejorar la toma de decisiones basada en datos, alineando la analítica con objetivos estratégicos del negocio. Estos resultados son consistentes con hallazgos reportados en la literatura, donde se evidencia que la retención temprana y la estabilidad contractual son factores clave en la reducción del churn.

5. Conclusiones

El desarrollo de este proyecto permitió implementar una solución integral de ingeniería de datos en la nube, cubriendo de manera estructurada las etapas de ingesta, catalogación, transformación, almacenamiento y análisis de datos, utilizando servicios administrados de Amazon Web Services.

Desde una perspectiva técnica, el uso de una arquitectura serverless basada en Amazon S3, AWS Glue y Amazon Athena permitió construir un pipeline escalable, flexible y de bajo costo operativo. Esta aproximación reduce la necesidad de gestionar infraestructura y facilita la implementación de soluciones analíticas en entornos productivos.

Uno de los aprendizajes más relevantes del proyecto fue la importancia de la calidad de los datos dentro del proceso analítico. La fase de exploración y transformación evidenció que los datos crudos requieren un proceso riguroso de limpieza y estandarización para garantizar resultados confiables. En este sentido, el uso de herramientas como PySpark dentro de AWS Glue permitió aplicar transformaciones reproducibles y alineadas con buenas prácticas de ingeniería de datos.

Desde el punto de vista analítico, el proyecto permitió identificar patrones relevantes de churn, como la mayor probabilidad de cancelación en clientes con contratos mensuales y baja antigüedad. Estos hallazgos refuerzan la importancia de diseñar estrategias de retención enfocadas en las primeras etapas del ciclo de vida del cliente.

Adicionalmente, la integración de un componente de machine learning mediante Amazon SageMaker demostró el potencial de evolucionar desde análisis descriptivo hacia capacidades predictivas. Aunque el modelo implementado corresponde a una prueba de concepto, su desarrollo permitió validar la viabilidad de utilizar los datos del pipeline para anticipar el comportamiento de los clientes.

Desde una perspectiva de arquitectura, el proyecto evidencia cómo un enfoque basado en data lake puede servir como base para integrar diferentes capas de analítica, incluyendo consultas ad hoc y modelos de machine learning, dentro de un mismo flujo de datos.

Finalmente, este proyecto permitió consolidar conocimientos clave en AWS Data Engineering, así como fortalecer la capacidad de diseñar soluciones orientadas a la toma de decisiones basada en datos. Como línea futura, la arquitectura podría evolucionar incorporando capacidades de procesamiento en tiempo real, orquestación de pipelines y prácticas de MLOps para el despliegue y monitoreo de modelos en producción. Más allá de la implementación técnica, este proyecto demuestra cómo una arquitectura de datos bien diseñada permite transformar datos en capacidades analíticas y predictivas que generan valor real para el negocio.

6. Bibliografía

- Frederick Reichheld (1996). *The Loyalty Effect: The Hidden Force Behind Growth, Profits, and Lasting Value*. Harvard Business School Press.
- Harvard Business Review (2014). *The Value of Keeping the Right Customers*. Recuperado de https://hbr.org
- McKinsey & Company (2021). *The Value of Getting Personalization Right—or Wrong—is Multiplying*. Recuperado de https://www.mckinsey.com
- Amazon Web Services (2023). *AWS Well-Architected Framework*. Recuperado de https://aws.amazon.com/architecture/well-architected/
- Amazon Web Services (2023). *Analytics Lens – AWS Well-Architected Framework*. Recuperado de https://aws.amazon.com/architecture/
- Amazon Web Services (2023). *Amazon SageMaker Developer Guide*. Recuperado de https://docs.aws.amazon.com/sagemaker/
- Amazon Web Services (2023). *AWS Glue Developer Guide*. Recuperado de https://docs.aws.amazon.com/glue/
- Telco Customer Churn Dataset (2019). IBM Sample Data Sets. Disponible en Kaggle.